

Etiquetación Automática de Datasets de Clasificación Mediante Algoritmos de Clustering

Evaluación comparativa de K-Means, clustering jerárquico y modelos de mezcla gaussiana sobre el dataset Breast Cancer Wisconsin (Diagnostic)

9 de noviembre de 2026

Autores: *De La Fuente Nataly (Contribución: 33 %), Murillo Santiago (Contribución: 33 %) y Vargas Gabriel (Contribución: 33 %)*

Carrera: *Ingeniería en Ciencia de Datos e Inteligencia de Negocios*

Institución: *Universidad Privada del Valle (UNIVALLE) - Cochabamba, Bolivia*

Asignatura: *Inteligencia Artificial y Machine Learning II – Módulo de Aprendizaje No Supervisado*

Docente: *M.Sc. Ing. Oscar Contreras Carrasco*

Resumen del Proyecto

El presente proyecto aborda la etiquetación automática de datasets de clasificación mediante algoritmos de clustering, tomando como caso de aplicación el conjunto de datos *Breast Cancer Wisconsin (Diagnostic)*, cuyas etiquetas de diagnóstico se ocultan para simular un escenario sin etiquetar. La propuesta consiste en generar agrupamientos no supervisados sobre las variables morfológicas del tumor, asignar una clase a cada clúster a partir de un subconjunto reducido de observaciones etiquetadas y contrastar el resultado frente al diagnóstico real, tanto mediante métricas de validación interna y externa como a través del desempeño de modelos de clasificación entrenados con las etiquetas generadas. El proyecto busca determinar si el clustering puede reducir la dependencia del etiquetado manual en condiciones comparables a las del dataset empleado.

Palabras clave: Aprendizaje No Supervisado, Clustering, Etiquetación Automática, Clasificación Binaria, Diagnóstico Oncológico, Breast Cancer Wisconsin Dataset.

Índice

INTRODUCCIÓN **3**

I. GENERALIDADES **3**

1. Análisis de la Problemática 3
2. Objetivos 4
   - 2.1. Objetivo General 4
   - 2.2. Objetivos Específicos 4
3. Justificación del Proyecto 5

REFERENCIAS **6**

INTRODUCCIÓN

El aprendizaje supervisado depende de manera crítica de la disponibilidad de datos correctamente etiquetados, condición que con frecuencia no se cumple en aplicaciones reales, donde los datos disponibles carecen de etiquetas o solo las poseen de forma parcial. Este escenario es especialmente relevante en el ámbito clínico, donde asignar una etiqueta exige criterio especializado.

Frente a esta limitación, el aprendizaje no supervisado y, de forma más amplia, el aprendizaje semi-supervisado ofrecen una vía alternativa para reducir la dependencia del anotador humano *(Van Engelen & Hoos, 2020)*. En particular, el enfoque conocido como *cluster-then-label* agrupa las observaciones en función de su similitud estructural sin requerir una variable objetivo previa y luego asigna una clase a cada agrupamiento resultante. El presente proyecto evalúa si dichos agrupamientos, una vez asignados a una clase a partir de un conjunto reducido de observaciones etiquetadas, se aproximan de forma suficiente a las etiquetas reales de un problema de clasificación binaria. Para ello se emplea el dataset *Breast Cancer Wisconsin (Diagnostic)*, que contiene mediciones morfológicas de núcleos celulares obtenidas a partir de imágenes digitalizadas de biopsias por aspiración con aguja fina *(Street et al., 1993; Wolberg et al., 1995)*.

La elección de este dataset responde a que el diagnóstico binario (maligno/benigno) proporciona una etiqueta de referencia objetiva y clínicamente validada, lo que permite evaluar de forma directa la calidad de las etiquetas generadas de forma no supervisada.

I. GENERALIDADES

1. Análisis de la Problemática

El desarrollo de modelos de clasificación supervisada exige, como paso previo, contar con un conjunto de datos correctamente etiquetado. En la práctica, este requisito constituye el denominado **"cuello de botella de la anotación"**: es poco frecuente que los datos de aplicaciones industriales estén completamente etiquetados y la obtención de etiquetas resulta costosa en términos de trabajo y recursos financieros *(Fredriksson, Bosch, et al., 2020)*. En la misma línea, un estudio de caso con científicos de datos de dos empresas concluye que la industria continúa dependiendo en gran medida de la anotación manual *(Fredriksson, Mattos, et al., 2020)*.

Esta limitación es particularmente relevante en el ámbito clínico, donde cada observación debe ser revisada y clasificada por un especialista, lo que implica tiempo y costo, y puede volverse difícil de sostener cuando la disponibilidad de personal calificado es limitada.

Esta situación genera una brecha concreta: existen conjuntos de datos con variables predictoras completas pero sin la variable de clase correspondiente, o con etiquetas parciales, lo que impide su uso directo en algoritmos de clasificación supervisada. Ante este escenario, surge la pregunta de investigación que orienta el presente proyecto: **¿en qué medida un algoritmo de clustering, aplicado sobre las variables predictoras de un problema de clasificación binaria, es capaz de generar agrupamientos que, al ser mapeados a una clase, se aproximen de forma suficiente a las etiquetas reales del problema?**

Para efectos de este estudio, la aproximación se considerará suficiente cuando se cumplan simultáneamente dos criterios definidos a priori: (i) una Exactitud de Agrupamiento igual o superior al 90 %, y (ii) una diferencia no mayor a 5 puntos porcentuales, en exactitud y en sensibilidad de la clase maligna, entre un clasificador entrenado con las etiquetas generadas por clustering y el mismo clasificador entrenado con las etiquetas reales completas. En consecuencia, la **hipótesis de trabajo** plantea que al menos uno de los algoritmos evaluados cumplirá ambos criterios; en caso contrario, se concluirá que el enfoque no resulta suficiente bajo las condiciones estudiadas.

Delimitación del estudio. El alcance se restringe al dataset *Breast Cancer Wisconsin (Diagnostic)*, un conjunto tabular de 569 observaciones y 30 variables morfológicas, ya curado y cuyas clases pueden separarse con alta exactitud mediante modelos lineales simples *(Street et al., 1993)*. Dado que este dataset incluye las etiquetas reales, estas se ocultan durante el agrupamiento y se emplean únicamente como referencia de evaluación y para simular el subconjunto reducido de observaciones etiquetadas por un especialista. En consecuencia, las conclusiones serán válidas para escenarios de características comparables y no deben extrapolarse sin cautela a otros contextos clínicos.

Cabe precisar que la problemática no se limita a la ejecución de un único algoritmo de clustering: la evidencia empírica muestra que el desempeño de estos métodos varía considerablemente según la forma, densidad y solapamiento de los grupos subyacentes en los datos *(Jain, 2010; Xu & Tian, 2015)*, por lo que resulta necesario comparar más de un enfoque antes de concluir sobre la viabilidad del etiquetado automático en este caso.

Adicionalmente, si el agrupamiento no refleja las clases reales o la asignación de clase a los clústeres es incorrecta, el clasificador supervisado entrenado posteriormente hereda esos errores como si fueran verdad fundamental, fenómeno conocido como **propagación del ruido de etiquetas**. Por ello, la calidad de las etiquetas generadas debe evaluarse de forma explícita antes de utilizarlas, y el desempeño de los clasificadores debe medirse siempre frente a las etiquetas reales sobre un conjunto de prueba independiente *(Hastie et al., 2009)*.

2. Objetivos

2.1. Objetivo General

Evaluar la viabilidad de un enfoque de etiquetación automática basado en algoritmos de clustering para la generación de etiquetas de clase sobre el dataset *Breast Cancer Wisconsin (Diagnostic)*, entendida como el grado en que las etiquetas generadas permiten alcanzar un desempeño de clasificación comparable al obtenido con etiquetas reales.

2.2. Objetivos Específicos

- **Preprocesar** el dataset *Breast Cancer Wisconsin (Diagnostic)* mediante la partición estratificada en conjuntos de entrenamiento y prueba, la estandarización de las 30 variables con parámetros ajustados únicamente sobre el conjunto de entrenamiento – para evitar fuga de datos – y la reducción de dimensionalidad con Análisis de Componentes Principales (PCA) con fines exclusivamente de visualización.
- **Generar** etiquetas de clase a partir de agrupamientos no supervisados obtenidos con K-Means, clustering jerárquico aglomerativo y modelos de mezcla gaussiana (*Gaussian Mixture Models*) estimados mediante el algoritmo EM *(Dempster et al., 1977)*, implementados con la biblioteca scikit-learn *(Pedregosa et al., 2011)*, sobre las 30 variables estandarizadas y con $k = 2$ conforme a la naturaleza binaria del problema, asignando a cada clúster la clase predominante de un subconjunto reducido (5–10 %) de observaciones etiquetadas por un especialista y sin utilizar el diagnóstico durante el agrupamiento.
- **Validar** la calidad de los agrupamientos y de las etiquetas generadas mediante métricas de validación interna (coeficiente de Silhouette *[Rousseeuw, 1987]* e índice de Davies-Bouldin *[Davies & Bouldin, 1979]*) y externa (Exactitud de Agrupamiento, calculada mediante el Algoritmo Húngaro *[Kuhn, 1955]*; Índice de Rand Ajustado *[Hubert & Arabie, 1985]*; e Información Mutua Normalizada *[Strehl & Ghosh, 2002]*), tomando como referencia el diagnóstico real ocultado durante el proceso.
- **Comparar** el desempeño de modelos de clasificación supervisada (regresión logística y máquinas de soporte vectorial) entrenados con tres esquemas de etiquetas – las generadas por clustering, las reales completas y una fracción reducida (5–10 %) de etiquetas reales, equivalente al subconjunto empleado para asignar clases a los clústeres –, evaluados sobre un conjunto de prueba con etiquetas reales mediante exactitud y sensibilidad de la clase maligna.

3. Justificación del Proyecto

Justificación Académica. El proyecto articula el aprendizaje no supervisado – agrupamiento, reducción de dimensionalidad y validación de clústeres – con un problema de clasificación supervisada real, evidenciando que ambos paradigmas no son mutuamente excluyentes, sino complementarios dentro de un mismo flujo analítico. Esta integración trata al clustering no como un ejercicio exploratorio aislado, sino como un componente funcional dentro de un proceso más amplio de generación de conocimiento a partir de datos no etiquetados, una perspectiva con aplicabilidad directa en cualquier escenario de investigación o de industria donde la disponibilidad de etiquetas de calidad sea limitada.

Justificación Práctica. El cuello de botella de la anotación afecta de forma transversal a los proyectos de *Machine Learning* aplicados *(Fredriksson, Bosch, et al., 2020; Fredriksson, Mattos, et al., 2020)*, y en el ámbito clínico se agrava porque la asignación de etiquetas depende de especialistas cuya disponibilidad puede ser limitada. Evaluar de forma rigurosa si el clustering puede aproximar razonablemente el criterio diagnóstico de un especialista, y bajo qué condiciones, aporta evidencia útil para decidir cuándo esta técnica podría reducir la carga de etiquetado manual, sin pretender sustituir el criterio clínico definitivo. Asimismo, al comparar contra un clasificador entrenado con una fracción reducida de etiquetas reales, el estudio permite establecer si el enfoque aporta una ventaja concreta frente a la alternativa más simple de etiquetar manualmente un subconjunto pequeño.

Justificación Metodológica. El dataset *Breast Cancer Wisconsin (Diagnostic)* es un caso de estudio ampliamente utilizado en la literatura de *Machine Learning (Street et al., 1993; Wolberg et al., 1995)*, lo que permite contrastar los resultados obtenidos con trabajos previos y garantiza la reproducibilidad del análisis. Adicionalmente, al tratarse de un problema de clasificación binaria con una etiqueta de referencia objetiva, se dispone de un criterio de verdad para evaluar externamente la calidad del agrupamiento, algo que no siempre es posible en aplicaciones puramente exploratorias de clustering. Cabe reconocer, no obstante, que se trata de un conjunto curado y de tamaño reducido, por lo que los resultados constituirán una primera validación del enfoque y no una prueba de su generalidad.

REFERENCIAS

1. Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909

2. Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B (Methodological), 39*(1), 1–38. https://www.jstor.org/stable/2984875

3. Fredriksson, T., Bosch, J., & Holmström Olsson, H. (2020). Machine learning models for automatic labeling: A systematic literature review. En *Proceedings of the 15th International Conference on Software Technologies (ICSOFT 2020)* (pp. 552–561). SCITEPRESS. https://doi.org/10.5220/0009972705520561

4. Fredriksson, T., Mattos, D. I., Bosch, J., & Holmström Olsson, H. (2020). Data labeling: An empirical investigation into industrial challenges and mitigation strategies. En *Product-focused software process improvement* (PROFES 2020; Lecture Notes in Computer Science, Vol. 12562, pp. 202–216). Springer. https://doi.org/10.1007/978-3-030-64148-1_13

5. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.

6. Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

7. Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters, 31*(8), 651–666.

8. Kuhn, H. W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly, 2*(1–2), 83–97.

9. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

10. Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65.

11. Street, W. N., Wolberg, W. H., & Mangasarian, O. L. (1993). Nuclear feature extraction for breast tumor diagnosis. *Proceedings of SPIE, 1905*, 861–870. https://doi.org/10.1117/12.148698

12. Strehl, A., & Ghosh, J. (2002). Cluster ensembles – A knowledge reuse framework for combining multiple partitions. *Journal of Machine Learning Research, 3*, 583–617. https://www.jmlr.org/papers/v3/strehl02a.html

13. Van Engelen, J. E., & Hoos, H. H. (2020). A survey on semi-supervised learning. *Machine Learning, 109*(2), 373–440.

14. Wolberg, W. H., Street, W. N., & Mangasarian, O. L. (1995). *Breast Cancer Wisconsin (Diagnostic) Data Set* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic

15. Xu, D., & Tian, Y. (2015). A comprehensive survey of clustering algorithms. *Annals of Data Science, 2*(2), 165–193.